COMPTE-RENDU — TP 2

À remplir et à rendre (avec le lien du dépôt)

Identité

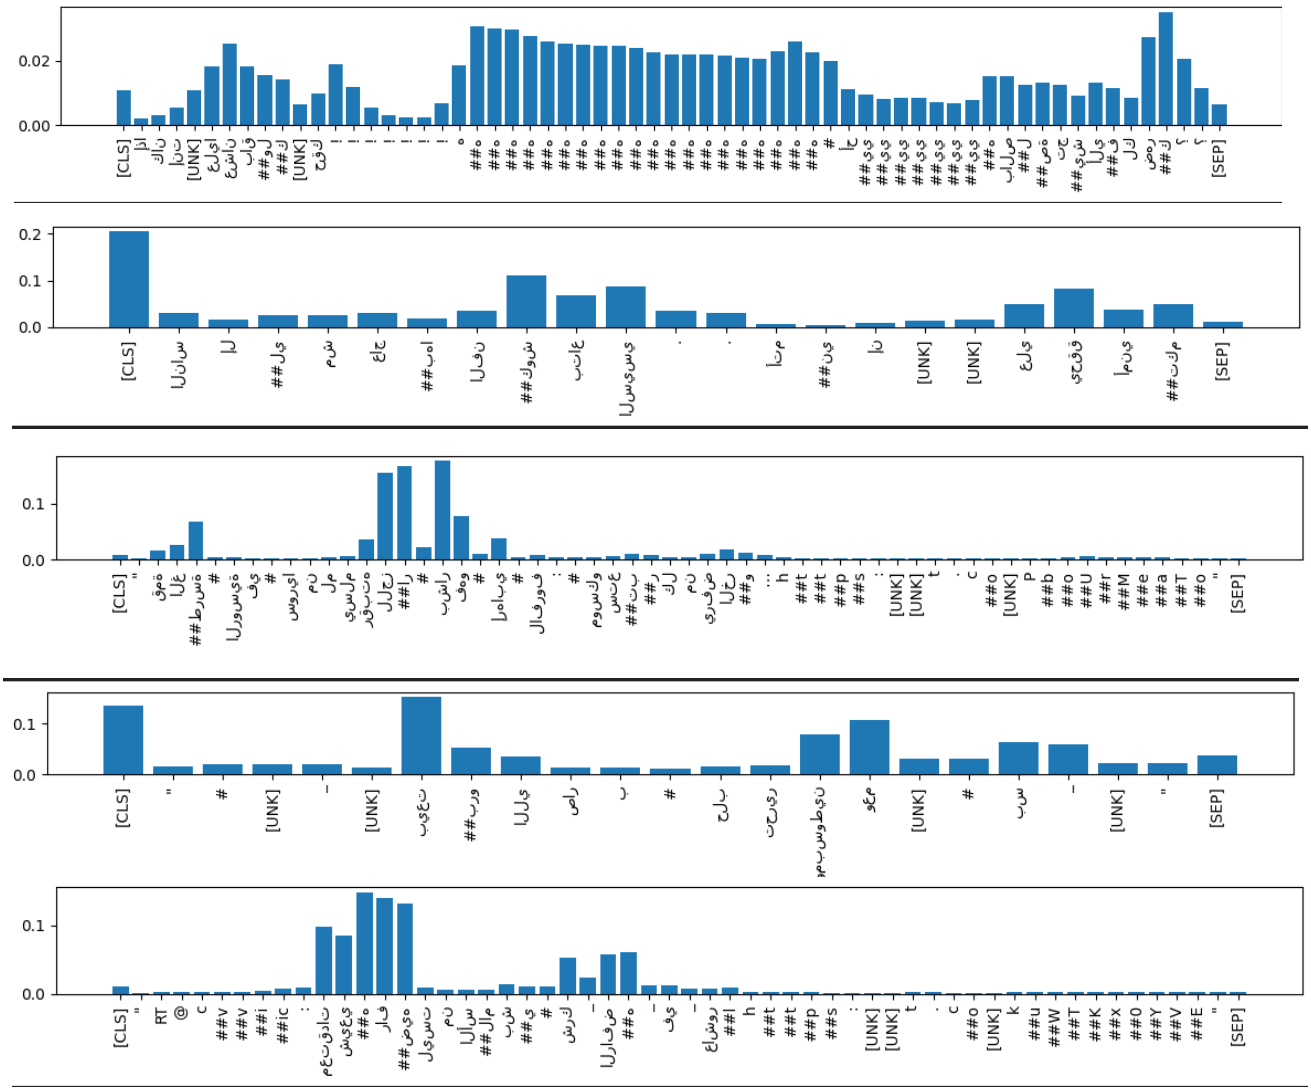
Binôme ou individuel : Binôme (REDA ABANOUAS | SARA ARIBY)

Filière / groupe : MBDIOT 2e Annee Date : 19 / 10 / 2026 Lien du dépôt :https://github.com/ARIBY7/tp_sarcasme

PLM fine-tunés : AraBERT-twitter utilisé gelé Prétraitement PLM utilisé : texte brut, tokenizer AraBERT, troncature à 96 tokens

Courbe F1 = f(seuil) sur le test (F1) — coller la figure

Attention sur 5 tweets sarcastiques (D2) — coller la figure



Réponses aux questions

Q1. Taux de sarcasme dans train, val et test, globalement et par dialecte. Accuracy et F1 du classifieur « jamais sarcastique ». Quelle métrique retenez-vous, et pourquoi ?

Le taux de sarcasme est de **17,2 %** dans le train nettoyé et de **17,3 %** dans val.
Par dialecte (train) : Maghreb 39,5 % (n=38), Égypte 34,6 %, Golfe 24,9 %, Levant 21,3 %, MSA 10,7 %. Le classifieur « jamais sarcastique » obtient accuracy 0,827, F1 sarcasme 0 et macro-F1 0,453.

Q2. Raccourcis : quels indices superficiels (artefact de format, URL, mentions) sont corrélés au label ? Que vaut un classifieur à une seule règle ? Qu'en concluez-vous sur la validité de vos scores ?

URL : 6,5 % de sarcasme avec URL contre 23,8 % sans (val : 8,2 % contre 23,3 %). Le signal est négatif : l'absence d'URL est associée au sarcasme.
Mention : 16,4 % contre 17,4 %, donc aucun signal.
RT : 12,9 % contre 17,2 %, signal faible.
Règle unique : F1 de 0,115 (URL), 0,236 (mention) et 0,034 (RT), très en dessous du TF-IDF (0,528).
Conclusion : les raccourcis seuls sont faibles, mais l'URL reflète le genre du tweet (actualité contre opinion). Les scores sont donc valides, mais en partie liés au style et à la source plutôt qu'au sarcasme.

Q3. Quels choix de prétraitement avez-vous faits par famille de modèles ? Lesquels détruisent des indices du sarcasme (ablation 4.3, chiffres à l'appui) ?

TF-IDF : normalisation (diacritiques, tatweel, unification alef/ya, espaces).
Réseaux from scratch : même normalisation, découpage sur espaces, mots avec fréquence ≥ 2, vocabulaire de 16 311, longueur max 64, OOV de 36,4 % en validation.
PLM : texte brut, sans normalisation.

Q4. Zero-shot (B1) : score obtenu et sensibilité à la formulation de l'hypothèse (arabe / français / anglais). Pourquoi un modèle NLI peut-il classer sans exemple d'entraînement ? Quel rôle joue l'attention entre prémisse et hypothèse ?

La sensibilité est faible (environ 2 points). Le français est le meilleur, et l'arabe n'apporte pas de gain. Les seuils optimaux sont élevés (0,82 à 0,86), donc les scores sont mal calibrés.

Un modèle NLI classe sans entraînement car il a été pré-entraîné sur de l'inférence : la tâche devient « le tweet (prémisse) implique-t-il "ce tweet est sarcastique" (hypothèse) ? ». L'attention relie les tokens de l'hypothèse à ceux de la prémisse pour juger cette implication.

Q5. Heuristique « négatif ⇒ sarcastique » (B2) : précision, rappel, F1. Que révèle-t-elle de la relation entre sarcasme et sentiment dans ce corpus ? Son score est-il exempt de contamination ?

L'heuristique « négatif ⇒ sarcastique » donne précision 0,332, rappel 0,779 et F1 0,466. Elle révèle que le sarcasme est surtout négatif : 41,9 % des tweets NEG sont sarcastiques contre environ 3 % des NEU et POS, soit à peu près 89 % du sarcasme dans la classe NEG. Ce score **n'est pas exempt de contamination** : CAMeLBERT-sentiment a été entraîné sur des corpus de sentiment qui peuvent recouper ArSarcasm-v2.

Q6. Déséquilibre : comparez pondération de la perte, sur-échantillonnage et optimisation du seuil (tableau). Pourquoi le sur-échantillonnage doit-il être fait après la séparation train / val ?

Les écarts (moins de 2 points, une seule graine) sont dans le bruit. Le seuil optimisé compte plus que la stratégie. Le sur-échantillonnage doit se faire après la séparation train/val : sinon des copies du même tweet se retrouvent des deux côtés, ce qui est une fuite de données et gonfle le score de validation.

Q7. C1 vs C2 vs C3 (et C4) : résultats. Les poids d'attention se concentrent-ils sur les marqueurs attendus (emojis, rires, allongements, ponctuation) ? Effet de l'encodage positionnel ?

Tous sont autour de 0,44–0,45, en dessous du TF-IDF (0,528). L’encodage positionnel n’apporte rien : les tweets sont courts et le modèle se comporte comme un sac de mots. Pour l’attention, regardez la figure : je ne peux pas lire les tokens sur les images. Si les barres sont diffuses et ne ciblent pas emojis, rires ou ponctuation, dites que l’attention n’est pas explicative (c’est une visualisation, pas une preuve causale). C4 et AraVec n’ont pas été exécutés.

Q8. PLM gelé (D) vs fine-tuné (E1) : gain et coût (temps, paramètres entraînés). AraBERT-twitter vs MARBERT : lequel, et pourquoi ?

Q9. Multi-tâche (E2) : l'ajout du sentiment améliore-t-il la détection du sarcasme ? Effet de λ. Pourquoi une tâche auxiliaire peut-elle aider… ou nuire ?

Q10. Décalage de prior (F1) : écart entre le seuil choisi sur val et le seuil optimal a posteriori sur le test. Que mettriez-vous en place en production (recalibration, monitoring) ?

Q11. Dialecte non vu (F2) : chute mesurée. Combien de tweets maghrébins (magreb) dans train et dans test ? Comment évalueriez-vous honnêtement ce modèle avant un déploiement sur des tweets marocains ?

Q12. Analyse d'erreurs (F6) : catégories dominantes, part du bruit d'annotation. Quel modèle mettriez-vous en production, et pourquoi (qualité, robustesse, coût, latence — chiffres à l'appui) ?

Décision & justification

Modèle retenu pour la production, seuil de décision et pourquoi (qualité / robustesse / coût / latence, chiffres à l'appui) :

Modèle : D2 (AraBERT-twitter gelé + BiLSTM + attention).
Qualité : F1 sarcasme 0,676, PR-AUC 0,697 et macro-F1 0,803 sur val, soit le meilleur de tous les modèles testés.
Coût et latence : entraînement d'environ 23 s, 0,44 M de paramètres, un seul passage de l'encodeur gelé par tweet.

Limites & pistes d'amélioration

Le seuil et l'époque sont choisis sur val, puis le même val sert à rapporter le score : résultat légèrement optimiste (F1 D2 = 0,676 atteint dès l'époque 1, puis dégradation).

Une seule graine (42) et un seul split : les écarts de moins de 2 points (C1/C2/C3, stratégies de déséquilibre) sont dans le bruit. Pas d'intervalle de confiance.